Laporan Praktikum 2 Data Mining

Nama : Rakha Makarim
NRP : 5054251010

1. Dataset

Dataset yang digunakan pada praktikum kali ini adalah *House Prices - Advanced Regression Techniques,* dataset yang biasa digunakan untuk memprediksi harga jual dari sebuah rumah. Tapi untuk praktikum kali ini data ini hanya digunakan untuk uji coba pra preprocessing yang telah ditetapkan dengan menggunakan file *train.csv* nya saja.

File *train.csv* transaksi properti residensial dengan 1 kolom identitas (Id), 79 fitur, dan 1 target (SalePrice). Dengan kolom numerik dan kategorikal sebanyak 38, 43, tanpa data duplikat. Missing value yang ditemukan sebanyak 7.829 data.

Parameter	Nilai
Jumlah baris	1.460
Jumlah kolom	81 (Id + 79 fitur + SalePrice)
Kolom numerik	38
Kolom kategorikal	43
Baris duplikat	0
Total missing values	7.829

tabel 1 dataset train.csv

2. Data Cleaning

2.1 Jumlah nilai hilang pada setiap atribut

Feature	Missing_value	Proporsi%
PoolQC	1453	99.52
MiscFeature	1406	96.30
Alley	1369	93.77
Fence	1179	80.75
MasVnrType	872	59.73
FireplaceQu	690	47.26

LotFrontage	259	17.74
GarageType	81	5.55
GarageYrBlt	81	5.55
GarageFinish	81	5.55
GarageQual	81	5.55
GarageCond	81	5.55
BsmtExposure	38	2.60
BsmtFinType2	38	2.60
BsmtQual	37	2.53
BsmtCond	37	2.53
BsmtFinType1	37	2.53
MasVnrArea	8	0.55
Electrical	1	0.07

tabel 2 missing value per feature

2.2 Menangani missing value

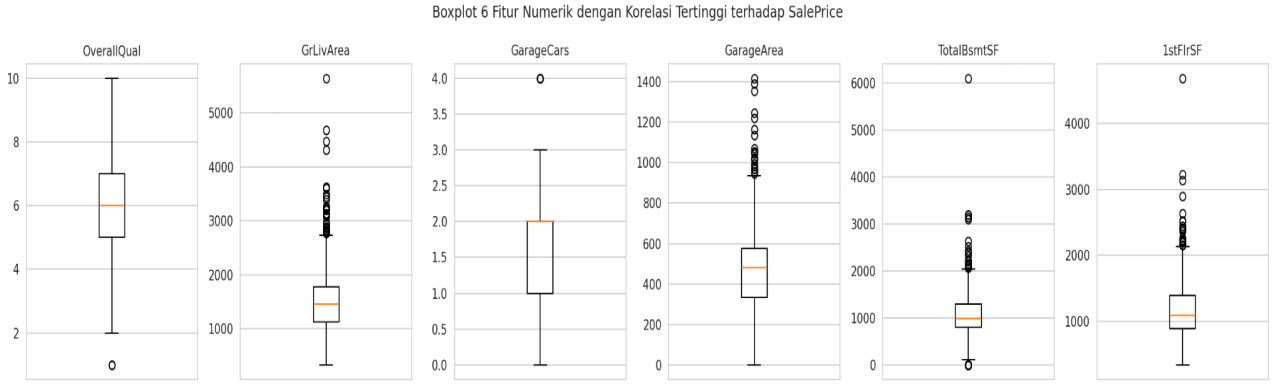
Pada kasus kali ini saya drop kolom yang memiliki missing value > 50% pada *tabel 2 missing value per feature* yaitu kolom Alley, MasVnrType, PoolQC, Fence, dan MiscFeature yang membuat shape data menjadi (1460, 76).

Kemudian untuk sisanya akan dilakukan penanganan khusu tergantung dengan tipe datanya. Untuk atribut **numerik** akan dilakukan metode pengisian **median,** sedangkan untuk **kategorikal** akan dilakukan metode pengisian secara **modus.**

3. Outlier Detection and Method

Deteksi outlier dilakukan menggunakan metode IQR (Interquartile Range) pada seluruh 38 atribut numerik. Suatu nilai dikategorikan sebagai outlier apabila berada di luar rentang [Q1 - 1,5xIQR, Q3 + 1,5xIQR]. Hasil deteksi menunjukkan 32 dari 38 atribut numerik memiliki setidaknya satu nilai pencilan, dengan total 1.678 titik data terindikasi outlier.

Untuk visualisasi, dipilih 6 fitur numerik dengan korelasi tertinggi terhadap SalePrice yang ada di *gambar 1.*



Gambar 1. Boxplot 6 fitur numerik dengan korelasi tertinggi terhadap SalePrice.

Menangani outlier pada kasus ini akan dilakukan capping ke batas IQR nya karena outlier pada data ini, misalnya LotArea atau SalePrice yang sangat besar, sebagian besar merepresentasikan rumah mewah yang valid, bukan kesalahan pencatatan. Menghapus baris data tersebut berisiko mengurangi jumlah data sekaligus menghilangkan informasi penting terkait properti bernilai tinggi. Dengan pendekatan capping, seluruh baris data tetap dipertahankan sementara pengaruh nilai ekstrem terhadap analisis selanjutnya (standarisasi dan korelasi) tetap terkendali.

Perlu dicatat, capping IQR tidak diterapkan pada 9 atribut yang memiliki Q1 = Q3 = 0 (mayoritas bernilai nol), yaitu BsmtFinSF2, LowQualFinSF, BsmtHalfBath, KitchenAbvGr, EnclosedPorch, 3SsnPorch, ScreenPorch, PoolArea, dan MiscVal. Pada atribut-atribut ini, IQR bernilai 0 sehingga batas capping menjadi [0, 0]; apabila tetap diterapkan, seluruh nilai non-nol (termasuk data valid, bukan outlier) akan ikut terpotong menjadi 0, membuat atribut tersebut kehilangan variansnya sepenuhnya dan berdampak pada perhitungan korelasi di tahap selanjutnya. Oleh karena itu, kesembilan atribut tersebut dipertahankan dalam bentuk aslinya tanpa proses capping.

4. Transformasi Data

4.1 Standarisasi Atribut Numerik

Seluruh atribut numerik distandarisasi menggunakan StandardScaler sehingga memiliki rata-rata (mean) 0 dan variansi (standar deviasi) 1. Standarisasi dilakukan setelah tahap penanganan outlier agar skala antar-atribut menjadi setara, sehingga tidak ada atribut yang mendominasi analisis akibat perbedaan satuan atau rentang nilai.

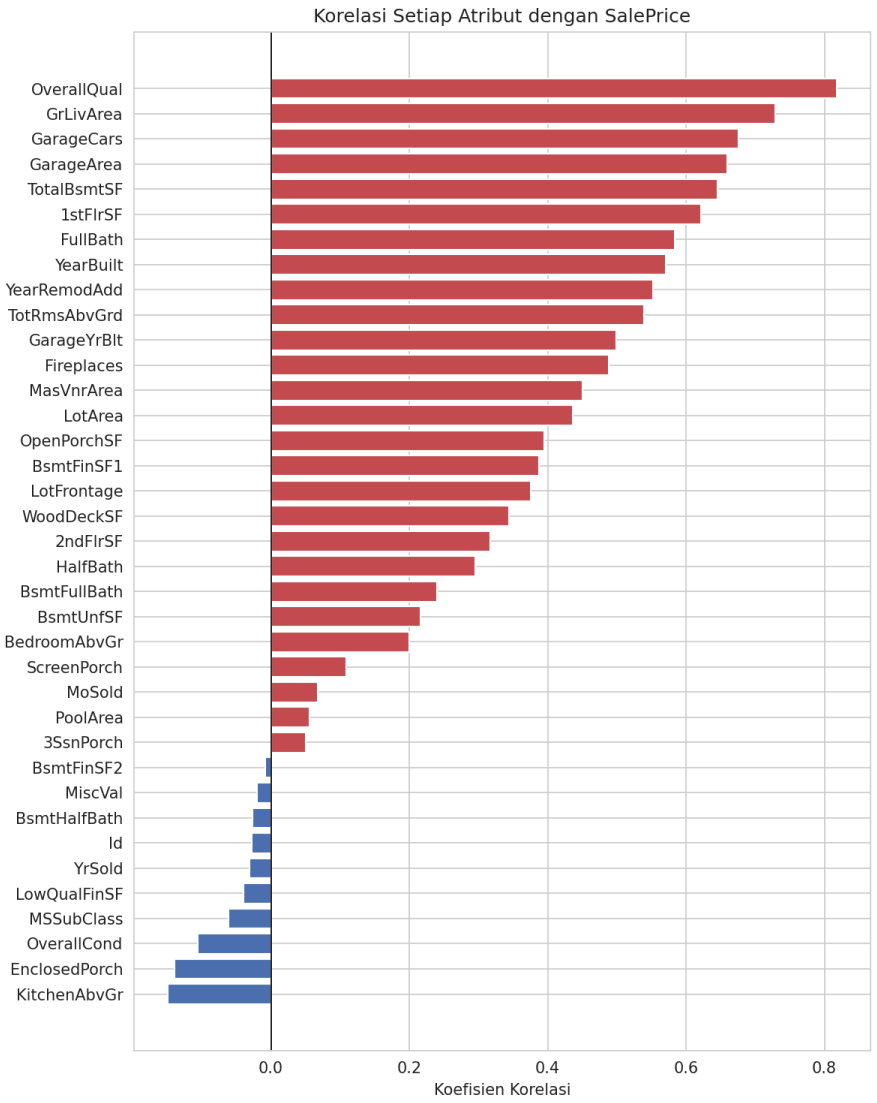
4.2 One-Hot Encoding Atribut Kategorikal

Atribut kategorikal diubah menjadi representasi numerik menggunakan one-hot encoding dengan memastikan redundansi kategorikal. Setelah proses ini, jumlah kolom dataset bertambah dari 76 menjadi 235 kolom, karena setiap kategori pada atribut kategorikal direpresentasikan sebagai kolom biner terpisah.

5. Reduksi data

5.1 Analisis korelasi terhadap SalePrice

Analisis korelasi Pearson dilakukan antara setiap atribut numerik dengan target SalePrice untuk mengidentifikasi atribut yang paling berpengaruh terhadap harga rumah. Hasil analisis ditampilkan pada Gambar 2.



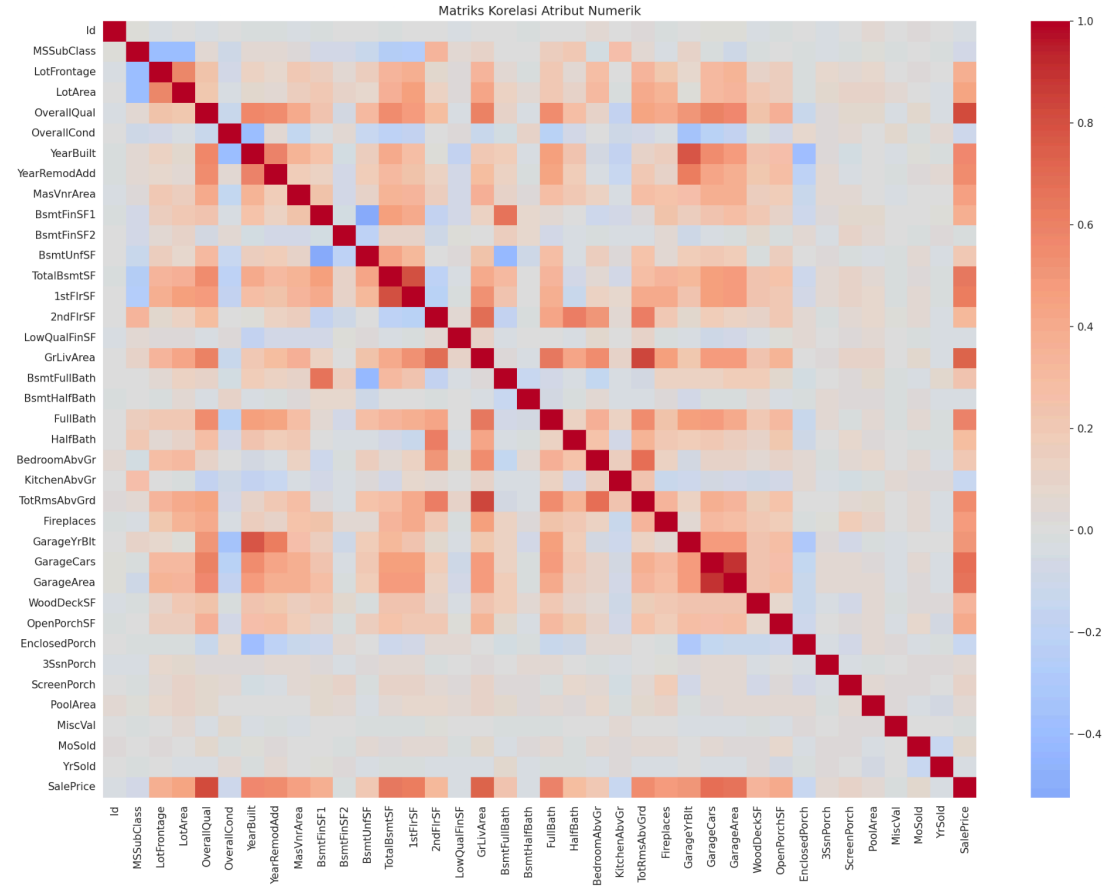
Gambar 2. Korelasi setiap atribut numerik dengan SalePrice.

Atribut dengan korelasi tertinggi terhadap SalePrice adalah OverallQual (0,82), GrLivArea (0,73), dan GarageCars (0,68), sementara atribut seperti KitchenAbvGr dan EnclosedPorch menunjukkan korelasi negatif lemah.

5.2 Penghapusan Atribut Berkorelasi Tinggi Antar-Fitur

Untuk mengurangi redundansi informasi, dilakukan analisis korelasi antar seluruh atribut (termasuk hasil one-hot encoding) pada Gambar 3. Atribut yang memiliki

korelasi absolut lebih dari 0,9 dengan atribut lain dianggap membawa informasi yang sama dan salah satunya dihapus.



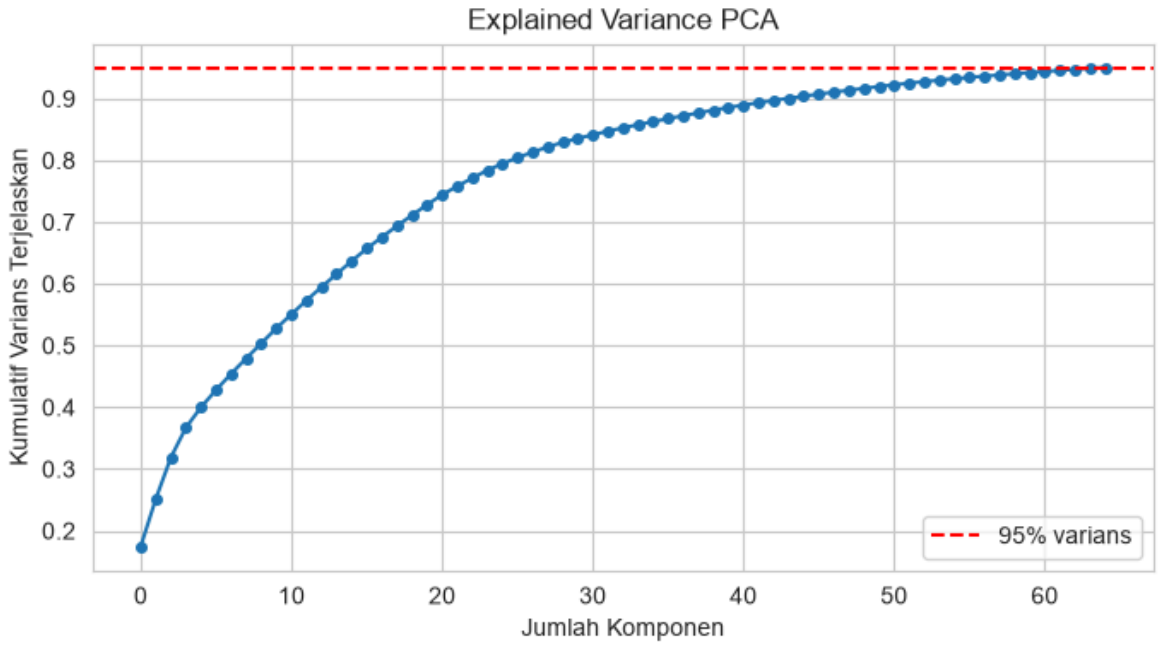
Gambar 3. Matriks korelasi atribut numerik.

Hasil analisis menemukan 7 atribut (seluruhnya merupakan hasil one-hot encoding) yang memiliki korelasi lebih dari 0,9 dengan atribut lainnya, yaitu RoofStyle_Hip, Exterior2nd_CBlock, Exterior2nd_CmentBd, Exterior2nd_MetalSd, Exterior2nd_VinylSd, ExterQual_TA, dan SaleCondition_Partial. Ketujuh atribut tersebut dihapus dari dataset karena membawa informasi yang sama dengan atribut pasangannya (contoh: Exterior2nd_CBlock berkorelasi sempurna, r = 1,00, dengan Exterior1st_CBlock).

Setelah tahap reduksi dimensi, jumlah kolom dataset berkurang dari 235 menjadi 228 kolom.

5.3 PCA (Principal Component Analysis)

Dengan mempertahankan komponen yang menjelaskan 95% varians data dimensi setelah dilakukan PCA menjadi 65 dari 228 sebelum PCA



Gambar 4. Grafik Cumulative Explained Variance

6. Ringkasan

Parameter	Sebelum	Setelah
Jumlah baris	1.460	1.460
Jumlah kolom	81 (Id + 79 fitur + SalePrice)	228 (setelah encoding & reduksi korelasi)
Kolom kategorikal	43	0 (seluruhnya numerik setelah one-hot encoding)
Total missing values	7.829	0
Atribut ter-capping (IQR)	-	29 dari 38 atribut numerik
Atribut dihapus (korelasi > 0,9)	-	7 atribut
Dimensi setelah PCA (95% varians)	-	65 komponen

tabel 3 Ringkasan dataset sebelum dan setelah praproses data.

Dataset akhir terdiri dari 1.460 baris dan 228 kolom, seluruhnya bertipe numerik tanpa missing value. Outlier telah dikendalikan melalui capping IQR, kecuali pada 9 atribut mayoritas bernilai nol yang dipertahankan aslinya. Reduksi dimensi melalui analisis korelasi dan PCA menghasilkan representasi data yang lebih ringkas (65 komponen) dengan tetap mempertahankan 95% informasi/varians dari data asli. Dataset ini siap digunakan untuk tahap pemodelan lebih lanjut.