LAPORAN PRAKTIKUM DATA MINING

Analisis Sequential Pattern pada Dataset Online Retail dengan PrefixSpan

Nama : Rakha Makarim
NRP : 5054251010
Program Studi : Rekayasa Kecerdasan Artifisial

1. Pendahuluan

Analisis *sequential pattern mining* digunakan untuk menemukan pola pembelian yang muncul secara berurutan berdasarkan riwayat transaksi pelanggan. Pada praktikum ini, saya menggunakan dataset *Online Retail* untuk melihat kecenderungan pembelian ulang maupun urutan produk yang sering dibeli. Algoritma *PrefixSpan* diterapkan untuk mencari pola, kemudian hasilnya dievaluasi melalui *support* dan *confidence*.

2. Dataset dan Eksplorasi Data

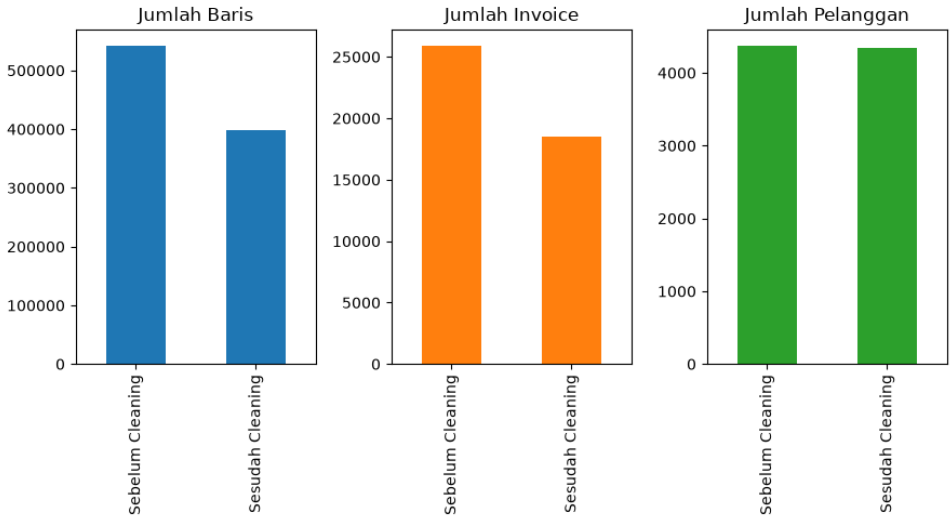
Dataset *Online Retail* memiliki 541.909 baris dan delapan atribut. Analisis berfokus pada *CustomerID* untuk mengidentifikasi pelanggan, *InvoiceNo* sebagai penanda transaksi, *InvoiceDate* untuk menentukan urutan waktu, dan *Description* sebagai nama produk. Kolom *Quantity* digunakan untuk menyaring pembelian yang valid. Pada pemeriksaan awal ditemukan 1.454 *missing values* pada *Description* serta 135.080 pada *CustomerID*.

3. Data Cleaning dan Transformasi

Tahap *data cleaning* dilakukan dengan menghapus baris yang tidak memiliki *Description* atau *CustomerID*, *canceled invoices* dengan awalan huruf C, dan transaksi dengan *Quantity* kurang dari atau sama dengan nol. Data bersih kemudian diurutkan berdasarkan pelanggan serta waktu transaksi agar rangkaian pembelian tetap kronologis.

Parameter	Sebelum	Sesudah
Jumlah baris	541.909	397.924
Invoice unik	25.900	18.536
Pelanggan unik	4.372	4.339

Tabel 1. Perbandingan dataset sebelum dan sesudah data cleaning.

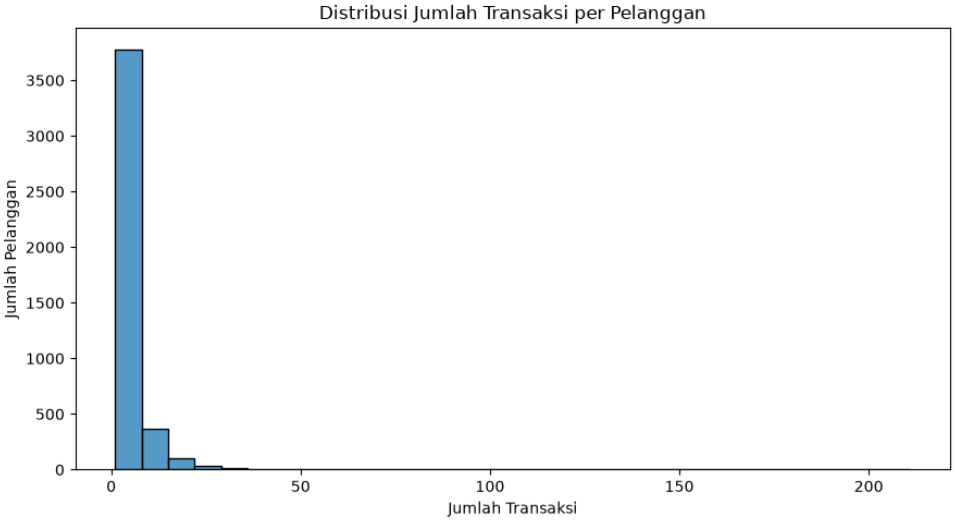


Gambar 1. Perbandingan jumlah baris, invoice, dan pelanggan.

Jumlah baris berkurang sebanyak 143.985 (26,57%), sementara invoice turun dari 25.900 menjadi 18.536. Perubahan jumlah pelanggan relatif kecil, yaitu 33 orang. Artinya, pembersihan terutama mengurangi catatan transaksi yang tidak sesuai kriteria tanpa menghilangkan sebagian besar pelanggan dari analisis.

4. Penerapan PrefixSpan

Setiap *invoice* disusun menjadi satu *itemset* berisi produk yang dibeli bersamaan. Seluruh *itemset* milik pelanggan lalu digabungkan menjadi *sequence* berdasarkan *InvoiceDate*. Hasil transformasi membentuk 4.339 *sequences* dengan 3.877 produk unik. Rata-rata pelanggan memiliki 4,28 transaksi, sedangkan nilai median berada pada dua transaksi.



Gambar 2. Distribusi jumlah transaksi per pelanggan.

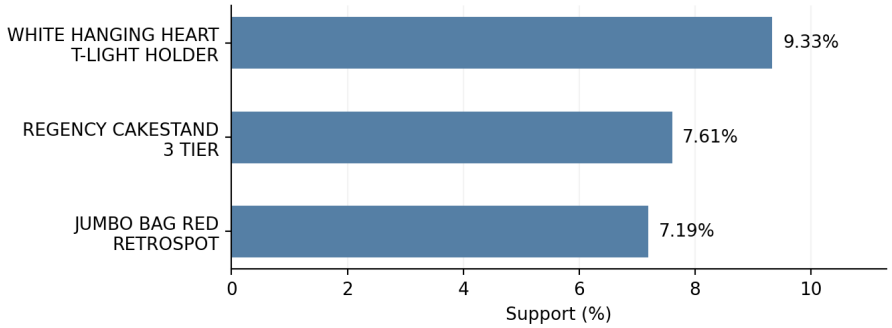
Distribusi tersebut terlihat *right-skewed* karena sebagian besar pelanggan hanya mempunyai sedikit transaksi, sedangkan beberapa pelanggan melakukan pembelian berulang dalam jumlah tinggi. Algoritma *PrefixSpan* dijalankan dengan *minimum support* 0,01 atau 1%. Proses ini menghasilkan 141.518 *frequent patterns*, termasuk 130.584 *sequential patterns* dengan minimal dua *itemsets*.

5. Hasil dan Pembahasan

5.1 Tiga Sequential Patterns dengan Support Tertinggi

No.	Sequential pattern	Support	Confidence
1	WHITE HANGING HEART T-LIGHT HOLDER → produk sama	9,33%	47,31%
2	REGENCY CAKESTAND 3 TIER → produk sama	7,61%	37,46%
3	JUMBO BAG RED RETROSPOT → produk sama	7,19%	49,13%

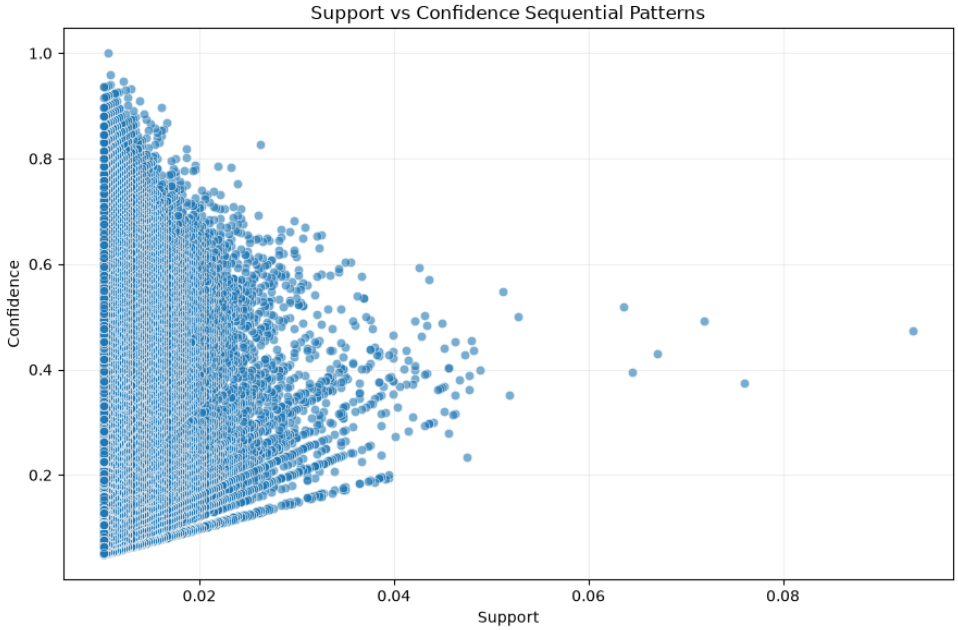
Tabel 2. Tiga pola pembelian berurutan berdasarkan support tertinggi.



Gambar 3. Perbandingan support dari tiga sequential patterns terbaik.

Pola pertama ditemukan pada 405 pelanggan atau sekitar 9,33% dari seluruh *sequences*. Produk REGENCY CAKESTAND 3 TIER muncul pada 330 pelanggan (7,61%), sedangkan JUMBO BAG RED RETROSPOT tercatat pada 312 pelanggan (7,19%). Ketiganya menunjukkan *repeat purchase*, yakni produk yang sama kembali muncul pada transaksi berikutnya, bukan hubungan pembelian dua produk yang berbeda.

5.2 Evaluasi Support dan Confidence



Gambar 4. Distribusi support dan confidence pada sequential patterns.

Support menunjukkan persentase pelanggan yang memiliki suatu pola, sementara *confidence* menggambarkan proporsi pelanggan dengan bagian awal pola yang juga memiliki kelanjutannya. Sebagian besar titik berkumpul pada *support* rendah dengan *confidence* yang bervariasi. Pola WHITE HANGING HEART T-LIGHT HOLDER memiliki *support* terbesar, tetapi *confidence* JUMBO BAG RED RETROSPOT lebih tinggi, yaitu 49,13%. Karena itu, frekuensi pola tidak selalu mencerminkan peluang kelanjutannya.

6. Kesimpulan

Penerapan *PrefixSpan* pada 4.339 *customer sequences* menghasilkan 130.584 pola berurutan dengan minimal dua *itemsets* pada *minimum support* 1%. Temuan utama memperlihatkan pembelian ulang untuk WHITE HANGING HEART T-LIGHT HOLDER, REGENCY CAKESTAND 3 TIER, dan JUMBO BAG RED RETROSPOT. Informasi ini dapat digunakan sebagai pertimbangan awal dalam *customer retention* maupun *repeat purchase recommendations*. Namun, pola yang ditemukan bersifat deskriptif dan tidak membuktikan hubungan sebab-akibat atau memastikan pelanggan akan melakukan pembelian berikutnya.